

Projet Environnemental

Marwa Dades
Amélie de Maillard
Mathis Rita

April 2025

1 Introduction

Le projet présenté dans ce rapport vise à évaluer la diversité et la répartition des odonates (libellules et demoiselles) au sein de la métropole bordelaise, à travers un protocole d'échantillonnage standardisé mis en œuvre entre 2018 et 2023. L'objectif est d'analyser la présence/absence de ces espèces dans les différents sites échantillonnés, en tenant compte des conditions environnementales et des types d'occupation du sol.

Les odonates, qui regroupent les libellules et les demoiselles, sont de bons indicateurs de la santé des milieux aquatiques. Ils réagissent facilement aux changements de leur environnement, comme la qualité de l'eau, l'état des bords de rivières ou les transformations du paysage. C'est pourquoi ils sont très utiles pour surveiller l'état des zones humides. Avec l'augmentation des villes et la pression des activités humaines sur la nature, il devient important de suivre de près les populations d'odonates, surtout à l'échelle locale.

Ce travail s'inscrit dans une démarche de suivi de la biodiversité dans la métropole de Bordeaux. L'objectif est de comprendre où se trouvent les différentes espèces d'odonates sur ce territoire, et à quelle fréquence on peut les observer, en tenant compte du fait qu'on ne les repère pas toujours facilement lors des relevés de terrain. Pour cela, on utilise un ensemble de données recueillies avec une méthode standard, ce qui permet de faire des analyses fiables à l'aide de modèles statistiques appelés modèles occupancy, développés avec le logiciel R.

1.1 Protocole d'échantillonnage

Le protocole d'échantillonnage mis en œuvre repose sur des relevés standardisés sur des sites prédéfinis au sein de la métropole bordelaise. Chaque site correspond à un point d'eau ou un linéaire de berge où les odonates sont susceptibles d'être présents.

Celui-ci repose sur une maille de 500m x 500m (25 hectares) dans laquelle plusieurs transects de 50m sont réalisés autour de plans d'eau et cours d'eau. Les transects sont prospectés selon les modalités suivantes :

- 4 passages pour les années 2019 et 2022,
- 3 passages pour les années 2018 et 2023.

L'approche multi-visites permet de distinguer les absences vraies (espèce absente) des absences dues à une non-détection (espèce présente mais non observée), ce qui est fondamental pour le modèle occupancy.

Les observations comprennent l'identification visuelle et par capture, dans des conditions météorologiques optimales. Les variables mesurées incluent :

- Date, heure de début, nom de l'observateur,
- Type d'habitat aquatique, recouvrement végétatif, pente,
- Température, vent, couverture nuageuse.

1.2 Description des données

Le jeu de données utilisé pour cette étude contient les informations suivantes :

- **Identifiants des sites** : Chaque ligne du jeu de données correspond à un passage sur un site donné, identifié par un code unique.
- **Dates de visite** : Les dates précises de chaque passage sont renseignées, permettant une analyse temporelle intra-saison.
- **Espèces observées** : La présence ou absence (ou le nombre) de chaque espèce d'odonate est notée pour chaque visite.
- **Variables de détection** : Conditions météorologiques, heure du jour sont enregistrées et utilisées comme covariables explicatives pour la probabilité de détection.
- **Variables de site** : Type de milieu, couverture végétale, présence de zones boisées à proximité, etc., sont utilisées pour modéliser la probabilité d'occupation.

Le format des données respecte une structure long format, avec plusieurs lignes par site (une par visite), ce qui facilite leur traitement pour les modèles d'occupancy.

2 Analyse des données

2.1 Préparation des données

Avant de pouvoir appliquer un modèle occupancy, il est essentiel de préparer les données de manière à les adapter aux exigences du package unmarked dans R. Cette étape nécessite la filtration, la transformation et l'alignement des données issues de plusieurs fichiers afin de construire une matrice de présence/absence compatible avec le format requis.

Nous avons tout d’abord importé les bibliothèques nécessaires à l’analyse :

- library(unmarked)
- library(dplyr)
- library(tidyr)
- library(ggplot2)

Trois jeux de données ont été utilisés :

- data : “Odonates up to 2023 common species.csv”
- lieu : “BiodiverCite sites up to 2023.csv”
- surface : “LandUsePerBM 2023 cartoISea.csv”

Dans le cadre de ce travail, chaque groupe s’est vu attribuer une espèce cible. Pour notre étude, nous avons eu la libellule *Lestes barbarus* (Fabricius, 1798). Le jeu de données data a donc été filtré pour ne conserver que les observations correspondant à cette espèce.

Le fichier lieu contient les passages par site sous forme de colonnes par année. Or, pour modéliser l’occupation, nous avons besoin d’une matrice où chaque site est en ligne, et chaque visite en colonne. Il a donc fallu réorganiser les colonnes des années en multipliant chaque année par le nombre réel de passages effectués : trois pour 2018 et 2023, et quatre pour 2019 et 2022.

Initialement, les valeurs présentes dans lieu indiquaient si un site avait été prospecté (1) ou non (0). Nous avons remplacé les 0 par NA (non-échantillonné) et les 1 par 0 (visité, mais aucune détection, par défaut) pour initialiser la matrice. Nous avons ensuite associé chaque ligne à un identifiant de site. Puis, nous avons renommé les colonnes pour représenter clairement chaque passage (ex : 2019.3 signifie troisième passage en 2019).

Pour remplir la matrice de détection mat_y, nous avons extrait la variable visite de data_filtree, en concaténant l’année et le numéro de passage. Nous avons ensuite parcouru ligne par ligne les données filtrées, et inscrit une détection (1) dans la cellule correspondante si l’espèce avait été observée.

À ce stade, la matrice mat_y contient les valeurs suivantes :

- 1 : l’espèce a été détectée,
- 0 : l’espèce n’a pas été détectée,
- NA : le site n’a pas été visité à cette date.

Enfin, le fichier surface a été filtré pour ne conserver que les données correspondant à un rayon de 500 mètres autour des sites. Cette échelle a été choisie car elle est adaptée à l’écologie de l’espèce étudiée, qui a une faible capacité de dispersion.

Ensuite, le jeu de données principal a été divisé selon les différentes visites effectuées chaque année, en tenant compte du nombre réel de passages par an (par exemple, trois passages seulement en 2018, malgré le protocole initialement

prévu à quatre). Cette opération permet de préparer séparément les informations de chaque session d'observation, notamment les variables environnementales pouvant influencer la détection de l'espèce.

Nous devons donc choisir les variables que nous souhaitons utiliser pour le modèle afin de les préparer. Nous avons décidé de ne pas conserver les variables qui possédaient beaucoup de valeurs manquantes ainsi que celles qui ne nous semblaient pas pertinentes ou qui avaient des valeurs difficiles à exploiter. Par exemple, la couverture nuageuse est une tranche de pourcentages ce qui est délicat pour en faire une moyenne et une analyse par la suite. Nous souhaitons conserver la surface des plans d'eau mais la variable possédait beaucoup de NA. Nous avons finalement conservé 4 variables qui nous semblaient importantes et utilisables dans notre modèle.

Pour chaque visite identifiée (par exemple 2018.1, 2019.2, etc.), un sous-ensemble des données a été créé. Ces sous-ensembles ont ensuite été traités de manière systématique pour calculer des variables moyennes par site (maille de 500 m) :

- Température moyenne (`Temperature_moy`) : Moyenne des températures relevées pour chaque Code_Maille au cours d'un passage donné.
- Recouvrement de végétation arborée (`RVArb_moy`) : Moyenne du pourcentage de végétation arborée autour des zones d'observation.
- Recouvrement de végétation aquatique (`RVAq_moy`) : Moyenne du recouvrement de la végétation aquatique, indicateur important de l'état du milieu.

Afin d'éviter les doublons et de garantir une seule ligne par site pour chaque passage, les doublons sur la colonne Code_Maille ont été supprimés. Une transformation des dates a également été effectuée, afin d'obtenir des dates juliennes (nombre de jours écoulés depuis le 1er janvier), facilitant l'inclusion de la variation saisonnière dans les modèles.

Par ailleurs, nous avons pu repérer afin de corriger d'éventuelles incohérences, comme l'absence du site E4015N64305 pour le troisième passage de 2019. Une fois cette erreur identifiée, les données ont été rectifiées afin d'assurer la cohérence du tableau de détection.

Enfin, les valeurs moyennes calculées ont été fusionnées au sein de tableaux récapitulatifs par variable (`df_Temperature`, `df_RVArb`, `df_RVAq`, `df_date_jul`), chacun structuré selon le format long, avec une colonne par passage et les Code_Maille en ligne. Ces tableaux sont prêts à être intégrés en tant que covariables explicatives de la détection dans le cadre des futurs modèles d'occupancy.

Pour intégrer la variable d'artificialisation dans le modèle, nous avons utilisé l'information issue du fichier `surface_filtree`, contenant notamment l'indice MOS11, indicateur de l'artificialisation du site. Une copie de la matrice `mat_y`, qui encode les détections d'odonates (présence = 1, absence = 0, non-observation = NA), a été utilisée pour créer une nouvelle matrice artificialisation.

Dans cette dernière, les valeurs 0 et 1 de détection ont été remplacées par les valeurs correspondantes de MOS11, à partir de la correspondance entre le code du site (`code_site`) et l'identifiant (ID) dans le jeu `surface_filtree`. Ainsi, la matrice artificialisation reflète le degré d'artificialisation pour chaque site visité.

Par la suite, un filtrage des sites a été effectué. En effet, certains sites présents dans la matrice initiale `mat_y` n'étaient pas associés à des données d'observations réelles d'odonates (données manquantes ou non concernées). Pour garantir la cohérence avec le jeu principal des odonates, seuls les sites apparaissant dans le jeu `data` ont été conservés. Cette opération a permis de restreindre l'analyse à 44 sites valides.

Enfin, un tri alphabétique a été appliqué à l'ensemble des matrices (matrice de détection `y_finale` et matrices des covariables environnementales : `df_date_jul`, `df_Temperature`, `df_RVAq`, `df_RVArb`). Ce tri garantit l'alignement parfait des lignes entre les différentes matrices, condition essentielle pour la création de l'objet `unmarkedFrame` et pour le bon fonctionnement du modèle `occupancy`.

Dans le cadre de notre modèle d'`occupancy`, nous avons souhaité étudier l'effet de plusieurs covariables environnementales sur la probabilité de présence de l'espèce cible. Parmi celles-ci, l'artificialisation a été utilisée comme covariable `site` (`siteCovs`), représentant une caractéristique fixe du site d'échantillonnage.

Nous avons extrait cette information depuis le jeu de données `surface_filtree`, en ne conservant que la variable MOS11, qui correspond à la proportion de surfaces artificialisées autour de chaque maille. Seules les mailles correspondant aux sites présents dans le jeu de données d'observations ont été retenues. Cette variable a ensuite été ordonnée et convertie en vecteur numérique (`artif_finale`) afin d'être utilisée dans le modèle.

Les différentes matrices de covariables d'observation, à savoir :

- la date julienne (`df_date_jul`),
- la température (`df_Temperature`),
- le recouvrement de végétation aquatique (`df_RVAq`),
- et le recouvrement de végétation arbustive (`df_RVArb`)

ont été converties en matrices numériques, tout en conservant les valeurs manquantes (NA) qui se trouvent aux mêmes endroits que ceux de notre matrice de détection de notre libellule `y_finale`. De même, la matrice de détection `y_finale`, représentant la présence (1), l'absence (0), ou les cas non observés (NA) pour chaque site et passage, a également été convertie au format matriciel.

L'ensemble des données a été intégré dans un objet de type `unmarkedFrameOccu`, qui permet d'organiser les informations selon les exigences du package `unmarked` :

- `y` : matrice de présence/absence,
- `siteCovs` : covariable fixe artificialisation,
- `obsCovs` : covariables d'observation variables selon les passages.

Le modèle occupancy a ensuite été ajusté à l'aide de la fonction `occu`, en spécifiant la structure suivante :

- Probabilité de détection (partie droite de $\sim$) : modulée par les variables date julienne, température, `RVAq`, et `RVArb`.
- Probabilité de présence (partie gauche de $\sim$) : modulée uniquement par l'artificialisation.

Un résumé du modèle (`summary(mod_occu)`) a été généré afin d'interpréter les coefficients estimés et leur signification statistique.

2.2 Interprétation des résultats

2.2.1 Modèle occupancy

Après avoir préparé les données pour pouvoir les utiliser dans `unmarked`, nous avons sorti un modèle occupancy.

Malheureusement, avec la libellule de départ *Lestes barbarus* (Fabricius, 1798), le ratio des 0/1 que l'on retrouve dans notre matrice de détection générait un message d'erreur pour le modèle. En effet, cette libellule était très peu observée (faible nombre de site occupés par la libellule) et nous ne pouvons donc pas en sortir un modèle adapté. Alors, nous avons vu avec le professeur, et nous avons donc analysé la libellule *Calopteryx virgo* (Linnaeus, 1758) qui est présente sur plus de site. Par la suite, les résultats correspondent à la libellule *Calopteryx virgo* après avoir suivi le même procédé de préparation que pour notre libellule de départ.

Nous avons ajusté un modèle d'occupancy à l'aide de la fonction `occu()` du package `unmarked` pour étudier l'effet de l'artificialisation (variable `MOS11`) sur la probabilité de présence de *Calopteryx virgo*, tout en prenant en compte plusieurs covariables influençant la probabilité de détection, à savoir : la date julienne, la température, le recouvrement de végétation aquatique (`RVAq`) et arbustive (`RVArb`).

Mathématiquement la probabilité de détection est :

$$p_{ij} = \text{logistic}(\mu_p + \alpha_1 \text{Datejulienne}_{ij} + \alpha_2 \text{Température}_{ij} + \alpha_3 \text{RVAq}_{ij} + \alpha_4 \text{RVArb}_{ij})$$

Puis la probabilité de présence se note :


$$\psi_i = \text{logistic}(\mu_\psi + \gamma_1 \text{Artificialisation}_{ij})$$

Le paramètre associé à l'artificialisation présente une valeur estimée de -0.44, avec un écart-type de 3.33, ce qui conduit à une statistique z de -0.13 et une p -valeur de 0.89. Cette absence de significativité statistique ($p > 0.05$) suggère que l'artificialisation n'a pas d'effet détectable sur la probabilité de présence de *Calopteryx virgo* dans les sites étudiés. Autrement dit, dans ce jeu de données, cette espèce ne semble pas être significativement influencée (positivement ou négativement) par l'artificialisation à l'échelle du buffer de 500 m.

En revanche, plusieurs covariables influençant la détection se révèlent statistiquement significatives, mais avec des valeurs très faibles :

- **Intercept de détection** : estimé à 3.45, significatif ($p = 0.0128$), ce qui indique une probabilité de détection de base assez élevée en moyenne.
- **Date julienne** : estimation négative (-0.0094 ; $p = 0.038$), ce qui indique que la probabilité de détecter *Calopteryx virgo* diminue au fil de la saison (plus tard dans l'année), malgré que l'estimation soit extrêmement faible. (voir Figure 1)
- **Température** : effet négatif significatif (-0.1621 ; $p = 0.00087$), suggérant que des températures plus élevées réduisent la probabilité de détection. Cela peut être lié à des changements de comportement (repos, vol réduit) par forte chaleur. (voir Figure 2)
- **Recouvrement de végétation aquatique (RVAq)** : effet négatif significatif (-0.0292 ; $p = 0.0039$), indiquant que des plans d'eau fortement couverts de végétation aquatique peuvent gêner l'observation directe de l'espèce, mais cela est léger au vu de l'estimation qui est très proche de 0. (voir Figure 3)
- **Recouvrement de végétation arbustive (RVArb)** : effet positif très significatif (0.0455 ; $p < 0.000001$), ce qui signifie que les habitats plus boisés ou en bordure d'arbres favorisent la détection de l'espèce, possiblement en lien avec ses comportements de repos ou d'accouplement sur la végétation riveraine. (voir Figure 4)

Nous pouvons visualiser chacun des comportements grace aux graphiques suivants



Ce modèle met en évidence que, pour *Calopteryx virgo*, les facteurs influençant la détection sont à prendre en compte, malgré des estimations faibles de

l'influence des covariables.

En revanche, l'artificialisation des paysages n'apparaît pas comme un facteur structurant la probabilité de présence dans cette étude, sans doute dû au manque de certaines données et à la détection de l'espèce.

2.2.2 Analyses des puissances sur données simulées

Analyse de puissance ('Power analysis').

Puissance = $\Pr(\text{trouver un effet} \mid \text{effet présent}) = 1 - \beta$ où β est le risque de seconde espèce.

25 sites permanents

L'objectif ici est d'évaluer si, avec un plan d'échantillonnage similaire aux données disponibles (25 sites, 5 années, 3 passages par an), on a suffisamment de puissance statistique pour détecter un effet de l'artificialisation sur la probabilité d'occupation.

Pour cela, une simulation a été effectuée en supposant un effet moyen de l'artificialisation sur l'occupation avec un coefficient $\beta_\psi = 1$. Le processus est répété 200 fois pour estimer la proportion de modèles dans lesquels cet effet est détecté de manière significative ($p < 0.05$).

Voici les paramètres de simulations :

- 25 sites
- 5 années de suivi
- 3 visites par année
- Probabilité de détection constante : $p = 0.6$
- Effet simulé de l'artificialisation : $\beta_\psi = 1$
- Nombre de simulations : 200
- Seuil de significativité : $\alpha = 0.05$

Nous avons un résultat de 0.105, ce qui signifie que seulement 10.5% des simulations ont détecté un effet statistiquement significatif de l'artificialisation sur la probabilité d'occupation. Autrement dit, la puissance statistique du modèle est très faible pour ce design d'échantillonnage.

Une puissance de 10.5% est bien inférieure au seuil recommandé de 80% pour considérer qu'un test est fiable. Cela implique que, même si un effet réel existe dans la population (ici $\beta_\psi = 1$), il y a presque 90% de chances de ne pas le détecter avec le design actuel.

Le faible nombre de sites (25) est probablement le facteur limitant principal ici. Le modèle manque d'information pour estimer correctement l'effet de l'artificialisation.

Cela peut expliquer pourquoi, dans les données réelles, aucun effet significatif n'a été observé : ce n'est pas nécessairement parce que l'effet est nul, mais parce que le modèle manque de puissance pour le détecter.

Le design actuel (25 sites, 5 ans, 3 visites/an) ne permet pas de détecter de manière fiable un effet moyen de l’artificialisation sur l’occupation avec $\beta = 1$. Ainsi, on ne peut pas interpréter cet effet avec confiance, ni en conclure qu’il est absent. Pour augmenter la puissance du test, il serait nécessaire d’augmenter le nombre de sites suivis, ou potentiellement d’augmenter le nombre de visites par site.

De plus, une réduction du seuil de significativité (par exemple en utilisant un intervalle de confiance à 90% au lieu de 95%) augmenterait légèrement la détection d’effets potentiels. Cependant, compte tenu de la faible puissance globale du modèle, cette stratégie ne permettrait pas à elle seule d’obtenir une interprétation fiable de l’effet de l’artificialisation. En effet, passer d’un intervalle de confiance à 95% à un intervalle à 90%, c’est abaisser le seuil de significativité (de 0.05 à 0.10). On détecterait un peu plus souvent des effets “significatifs”, mais la puissance de notre test est seulement de 10.5% avec un seuil de 5%, elle ne grimpera pas à 80% avec un seuil de 10%. Autrement dit, le test reste très peu sensible, et nous avons toujours un risque élevé de faux négatifs.

20 sites permanents plus 5 sites flottants

Dans un second temps, nous avons évalué la puissance statistique du modèle d’occupancy en utilisant un design d’échantillonnage plus complexe et potentiellement plus réaliste. Ce design comprend 20 sites permanents, suivis chaque année pendant 5 ans avec 3 visites par site et par an, ainsi que 5 sites flottants différents par an, également visités 3 fois chacun. Ce plan d’échantillonnage combine ainsi une composante temporelle forte (avec les sites permanents) à une diversité spatiale (avec les sites flottants renouvelés chaque année).

Pour réaliser cette analyse, nous avons simulé 200 jeux de données selon ce design, en imposant un effet réel d’artificialisation sur la probabilité d’occupation ($\beta = 1$). À chaque itération, nous avons ajusté un modèle d’occupancy via la fonction `occu()` du package `unmarked`, puis compté la proportion de cas où l’effet d’artificialisation était détecté comme significatif ($p < 0.05$).

L’exécution du code a abouti à une puissance de 0.99, indiquant que 99% des simulations ont détecté un effet significatif de l’artificialisation. Ce résultat témoigne d’une très forte puissance statistique, ce qui signifie que, si un effet de cette ampleur existe réellement dans la nature ($\beta = 1$) il sera détecté avec une très grande probabilité dans un tel plan d’échantillonnage.

Ce design mixte se révèle donc très efficace pour capter les effets d’une covariable sur l’occupation des sites. L’ajout de sites flottants chaque année permet d’élargir l’échantillon spatial et d’améliorer la représentativité, tandis que le suivi des sites permanents assure une bonne estimation des effets temporels. Ce compromis entre diversité spatiale et profondeur temporelle accorde une robustesse et une sensibilité élevées au modèle.

En conclusion, un tel plan d’échantillonnage est hautement recommandé si l’objectif est de détecter des effets modérés à forts sur la probabilité d’occu-

pation, en assurant à la fois une couverture spatiale suffisante et une stabilité temporelle des observations.

Cependant, la puissance obtenue dans cette seconde partie nous paraît particulièrement élevée par rapport à celle des 25 sites permanents. Nous pensons qu’il est normal que la puissance augmente en diversifiant les sites mais il nous semble qu’une augmentation aussi importante est étrange. Nous ne savons pas dire d’où peut venir cette aussi forte augmentation malgré l’ajout de 5 sites flottants.

3 Conclusion

Ce travail nous a permis d’aborder les différentes étapes de la modélisation occupancy en contexte écologique, depuis la préparation des données jusqu’à l’interprétation des résultats statistiques. À travers l’exemple de la libellule *Calopteryx virgo*, nous avons pu étudier l’influence potentielle de l’artificialisation sur la probabilité de présence d’une espèce, tout en tenant compte des facteurs influençant la détection.

Nos résultats montrent que, dans les conditions de notre jeu de données, l’artificialisation n’apparaît pas comme un facteur statistiquement significatif influençant la probabilité d’occupation de *Calopteryx virgo*. Cependant, plusieurs covariables liées à la détection, telles que la température, la date d’observation ou encore la végétation aquatique et arbustive, ont un effet significatif sur la probabilité de détection de l’espèce.

Cette absence d’effet de l’artificialisation pourrait s’expliquer non seulement par un éventuel manque de lien écologique réel, mais aussi par une puissance statistique insuffisante dans notre design d’échantillonnage initial. En effet, nos analyses de puissance ont révélé qu’avec 25 sites permanents, la probabilité de détecter un effet moyen était très faible (10.5%), rendant toute conclusion incertaine. En revanche, un design combinant 20 sites permanents et 5 sites flottants par an permet d’atteindre une puissance très élevée (99%), mettant en lumière l’importance du plan d’échantillonnage dans ce type d’analyse. En revanche, la puissance obtenue nous semble spécialement élevée par rapport au résultat que nous pensions trouver.

Ainsi, cette étude met en évidence deux éléments fondamentaux, d’une part, la nécessité de prendre en compte les biais de détection dans les analyses de présence/absence, d’autre part, l’importance cruciale d’un design d’échantillonnage adapté pour garantir la robustesse des résultats et la fiabilité des conclusions écologiques.

En conclusion, la modélisation occupancy est un outil puissant pour explorer les relations entre espèces et environnement, mais elle nécessite une rigueur méthodologique à toutes les étapes, et notamment une attention particulière à la qualité du design d’étude.