

Prédiction du prix de l'immobilier à Talence à l'aide de modèles linéaires mixtes

Master MSS — Université de Bordeaux

Auteurs : Mathis Rita et Amélie de Maillard

01 décembre 2025

Résumé

L'objectif de ce projet est d'expliquer les caractéristiques d'un bien immobilier qui influencent son prix de vente, et de prédire le prix de nouveaux biens sur le marché de la ville de Talence. Nous documenterons les corrélations attendues entre caractéristiques du bien (surface bâtie, nombre de pièces, surface de terrain) et prix, ainsi que le rôle de la localisation (quartier, coordonnées) dans l'explication de la variabilité. Pour cela, nous utilisons les données issues des Demandes de Valeurs Foncières (DVF) du gouvernement français, et nous appliquons des modèles linéaires mixtes afin de prendre en compte la variabilité entre quartiers.

1 Introduction

Le marché immobilier constitue un domaine d'étude privilégié pour les statisticiens et les économistes, en raison de la multiplicité des facteurs pouvant influencer la valeur d'un bien : la surface, le type de logement, le nombre de pièces, la localisation, ou encore la période de transaction.

Dans le cadre de ce projet, nous étudions les ventes immobilières réalisées à Talence entre 2020 et 2024 à partir des données DVF (Demandes de Valeurs Foncières). Ces données publiques recensent l'ensemble des mutations foncières et permettent d'effectuer des analyses fines du marché local.

Notre objectif est double :

- identifier les variables explicatives majeures du prix des biens ;
- construire un modèle capable de prédire le prix d'un nouveau bien immobilier, tout en tenant compte des effets de quartier et prédire le prix de biens immobiliers dans un nouveau quartier.

L'utilisation d'un **modèle linéaire mixte (LMM)** est ici justifiée par la structure hiérarchique des données, plusieurs biens sont regroupés par quartier (voir [figure 1](#)), et ces effets de contexte peuvent influencer le prix.

2 Préparation des données et exploration initiale

Les données sont fournies dans le fichier `data_Talence.Rdata` contenant les tables :

- `data_talence` : fichier de données de base (7597 observations et 42 variables) ;
- `newData_talence` : fichier des nouveaux biens où il faut prédire leur prix (1000 observations et 42 variables) ;
- `quartier_AK_missing` : fichier de données d'un nouveau quartier avec des prix manquants à prédire (413 observations et 42 variables).

Les analyses ont été effectuées sous le logiciel **R** à l'aide des bibliothèques `dplyr`, `ggplot2` et `lme4`, `lmerTest`, respectivement utilisées pour la manipulation, la visualisation et la modélisation des données.

Un premier aperçu des données a permis d'identifier la structure des variables et la présence de valeurs manquantes. Plusieurs variables administratives ou cadastrales jugées non pertinentes pour l'analyse du prix immobilier ont été supprimées. Cette étape de nettoyage a permis d'alléger la base et de se concentrer sur les caractéristiques principales des biens : surface, nombre de pièces, type de local et localisation.

L'exploration des données a d'abord permis d'identifier plusieurs doublons et valeurs extrêmes, notamment un bien dont la valeur foncière atteignait plus de 32 millions d'euros. Cette observation suggère la présence de ventes d'immeubles complets plutôt que de logements individuels. Ces valeurs aberrantes ont été retirées afin d'éviter qu'elles n'influencent les estimations du modèle.

La distribution du prix de vente montre une forte hétérogénéité entre les biens, avec une majorité de transactions comprises entre 150 000 € et 500 000 €. Les prix varient également selon le type de bien, les appartements présentent une surface moyenne d'environ 47m² pour un prix moyen proche de 360 000 € tandis que les maisons atteignent en moyenne 94m² pour un prix moyen d'un peu plus d'un million d'euros.

Afin d'assurer la cohérence des comparaisons, seules les catégories *Maison* et *Appartement* ont été conservées. Pour les appartements, les valeurs manquantes de surface de terrain ont été remplacées par 0, ces biens ne disposant pas de parcelle individuelle.

Ces préparations ont conduit à un sous-ensemble de 3 121 observations exploitables après nettoyage, prêt pour l'ajustement du modèle.

3 Modélisation

Formulation du modèle linéaire mixte

Le modèle linéaire mixte se justifie par le fait qu'il peut y avoir des biais que nous ne savons pas définir en amont. Nous avons pensé principalement à l'effet du quartier, les différences de localisation peuvent expliquer des différences d'attrait (dépendant des lieux, centre ville, etc) et donc de prix. Nous avons également pensé à nous intéresser aux appartements revendus (considérer l'aspect individuel des appartements car la revente peut impacter le prix) mais il y en avait peu et il était parfois difficile de déterminer si des appartements du même immeuble était revendu donc nous avons décidé de ne pas nous concentrer sur cet effet. Nous retenons donc tout d'abord un seul intercept aléatoire par quartier, cette spécification capture les décalages moyens de prix entre quartiers sans complexifier inutilement le modèle.

Le modèle linéaire mixte retenu s'écrit de la manière suivante :

$$Y_{ij} = \mathbf{x}_{ij}^T \boldsymbol{\beta} + \mathbf{b}_i + \varepsilon_{ij}$$

avec :

- Y_{ij} : valeur foncière du bien j (observation) appartenant au quartier i (variable Quartier) ;
- $\mathbf{x}_{ij}^T$: vecteur des covariables (nombre de pièces, surface bâtie, etc.) ;
- $\boldsymbol{\beta}$: vecteur des coefficients fixes à estimer ;
- $\mathbf{b}_i$: effet aléatoire associé au quartier i ;
- ε_{ij} : terme d'erreur aléatoire.

Les hypothèses de distribution sont les suivantes :

$$\varepsilon_{ij} \sim \mathcal{N}(0, \sigma_\varepsilon^2) \quad \text{et} \quad \mathbf{b}_i \sim \mathcal{N}(0, \sigma_b^2) \quad \text{avec} \quad \varepsilon_{ij} \perp \mathbf{b}_i$$

Le terme $\mathbf{b}_i$ représente l'influence spécifique du quartier i sur le prix moyen des biens,

permettant ainsi de modéliser la variabilité spatiale non expliquée par les covariables fixes.

Le modèle linéaire mixte a été estimé à l’aide de la fonction `lmer` du package `lmerTest` (voir [2]). La variable réponse est la **valeur foncière** en euros. Les effets fixes considérés sont la surface réelle bâtie, le nombre de pièces principales, la surface du terrain et le type de bien (*Maison* ou *Appartement*). Un effet aléatoire a été introduit pour le **quartier** afin de tenir compte de la variabilité spatiale ; les coordonnées (longitude, latitude) sont mobilisées dans les modèles améliorés, et une carte synthétique des prix moyens par quartier est fournie.

Chaque quartier possède ainsi un niveau moyen de prix spécifique via l’intercept aléatoire.

TABLE 1 – Effets fixes (**Modèle 1** : prix en euros, intercept aléatoire par quartier)

Variable	$\hat{\beta}$	Sd($\hat{\beta}$)	t	p
Intercept	49 312.68	136 907.74	0.360	0.720
Surface bâtie (m ²)	−1 081.48	1 954.69	−0.553	0.580
Nombre de pièces	114 182.97	46 329.16	2.465	0.014
Surface de terrain (m ²)	1 329.35	96.24	13.812	$< 10^{-16}$
Type = Maison	−17 990.68	91 941.86	−0.196	0.845
Variance inter-quartiers = 3.66×10^{11} ; variance résiduelle = 3.08×10^{12} ; ICC ≈ 0.106 .				

Les résultats indiquent que le nombre de pièces principales et la surface du terrain ont un effet significatif sur le prix de vente ($p < 0,05$), chaque pièce supplémentaire augmente en moyenne le prix d’environ 114 183 € avec un effet significatif et chaque mètre carré de terrain supplémentaire augmente le prix d’environ 1 329 € avec un effet très significatif. En revanche, la surface bâtie et le type de bien ne présentent pas d’effet significatif au seuil de 5%. Pour le type, même si l’effet est non significatif, il est étrange que le coefficient soit négatif mais cela pourrait venir du fait que les variables sont très corrélées. De plus, en général les appartements n’ont pas les mêmes caractéristiques que les maisons, ils sont plus petits, etc, ce qui peut fausser la comparaison. Les appartements ont peut être un prix du mètre carré plus élevé en général.

L’effet aléatoire associé au quartier affiche une variance de $3,66 \times 10^{11}$, la variance intra-quartiers affichée est de $3,08 \times 10^{12}$, cela signifie que la différence entre quartiers existent et est importante mais la variabilité du prix s’explique en majorité au sein même des quartiers. Il existe un lien fort entre la surface bâtie et le nombre de pièces, ce qui explique la non-significativité de la surface bâtie dans ce modèle brut ; cela motive l’usage d’un modèle sur $\log(\text{prix})$ et l’ajout d’une pente aléatoire par la suite.

L’indice de corrélation intraclasse (ICC) estimé à 0,106 indique qu’environ 11% de la variance totale du prix peut être attribuée aux différences entre quartiers. Ce résultat

justifie l'emploi d'un modèle mixte plutôt qu'un modèle linéaire simple.

3.1 Comparaison et amélioration des modèles

Afin d'améliorer la qualité prédictive, nous avons testé plusieurs extensions du modèle initial. Une première amélioration consiste à modéliser la **valeur foncière en échelle logarithmique**, ce qui stabilise la variance et réduit l'influence des valeurs extrêmes. L'ajout des coordonnées géographiques (longitude, latitude) permet également de prendre partiellement en compte les effets spatiaux liés à la localisation.

Une seconde extension introduit une **pente aléatoire de la surface bâtie par quartier**. Cette structure permet de relâcher l'hypothèse d'un effet uniforme de la surface sur le prix, la sensibilité du prix à la surface peut ainsi différer selon les quartiers (quartiers denses / pavillonnaires, par exemple).

La comparaison des AIC (critère qui combine qualité d'ajustement et complexité) entre les 3 modèles, permet de montrer que chaque amélioration augmente la qualité de l'ajustement.

TABLE 2 – Comparaison des AIC entre les modèles

Modèle	Transformation / effets	AIC
Modèle initial	prix brut, intercept aléatoire	≈ 98676.5
Modèle avec log-prix + coords	log(prix), intercept aléatoire	≈ 8146.1
Modèle final	log(prix), pentes aléatoires, centrage	≈ 8032.6

Ainsi, le modèle final est retenu car il possède l'AIC le plus petit. Cela confirme que l'effet de la surface varie significativement selon les quartiers.

3.2 Prédiction sur de nouveaux biens dans un nouveau quartier

Pour la prédiction sur le fichier `newData_talence`, seules les *Maisons* et *Appartements* ont été conservées. Les observations présentant trop de valeurs manquantes sur les variables essentielles (`surface_reelle_bati`, `nombre_pieces_principales`, `surface_terrain`) ont été écartées, car elles ne permettent pas une prédiction fiable. Les surfaces de terrain manquantes pour les appartements ont été remplacées par zéro (absence logique de parcelle), et les coordonnées manquantes ont été imputées par la moyenne du quartier (ou la médiane globale pour le quartier AK). Ces choix garantissent la cohérence structurelle entre le jeu d'apprentissage et le jeu de prédiction.

Pour un quartier inédit i^* (par exemple le quartier AK), la prédiction se fait à partir du modèle ajusté selon :

$$\hat{Y}_{i^*j} = \mathbf{x}_{i^*j}^T \hat{\boldsymbol{\beta}} + \mathbf{z}_{i^*j}^T \hat{\mathbf{b}}_{i^*},$$

où l'on prend par défaut $\hat{\mathbf{b}}_{i^*} = \mathbf{0}$ lorsqu'aucune information n'est disponible pour estimer un effet aléatoire spécifique (`allow.new.levels = TRUE` dans `predict`). Les intervalles de prédiction peuvent être élargis pour intégrer cette incertitude supplémentaire. Les résultats ont ensuite été représentés sur une carte de Talence, où la couleur de chaque quartier traduit le prix moyen prédit (du jaune pour les moins chers au rouge pour les plus chers, voir [figure 2](#) et [figure 3](#)).

3.3 Évaluation prédictive

L'erreur de prédiction a été mesurée par la racine de l'erreur quadratique moyenne (RMSE) sur la variable transformée $\log(\text{prix})$ puis retransformée en euros :

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{Y}_i - Y_i)^2}.$$

Le passage à la transformation logarithmique et l'ajout des effets aléatoires améliorent sensiblement la stabilité des prédictions. Le RMSE passe d'environ 310 k€ pour le modèle initial à environ 190 k€ pour le modèle logarithmique, puis à près de 185 k€ avec la pente aléatoire. Ces résultats traduisent une meilleure capture de l'hétérogénéité spatiale et structurelle des biens.

4 Conclusion

Ce travail montre qu'un modèle linéaire mixte avec effet aléatoire de quartier permet de capter une part importante de l'hétérogénéité spatiale des prix immobiliers à Talence. Après nettoyage des données et restriction aux *Maisons* et *Appartements*, l'ICC d'environ 11 % justifie l'introduction d'un effet aléatoire de quartier. La transformation $\log(\text{prix})$, l'ajout de variables de localisation (longitude, latitude) et l'introduction d'une pente aléatoire pour la surface bâtie améliorent la stabilité et la précision prédictive (diminution du RMSE sur le quartier AK d'environ 310 k€ à ~ 185 –190 k€).

Finalement, le nombre de pièces et la surface de terrain sont associés positivement aux prix, tandis que l'effet de la surface bâtie varie selon les quartiers, signe d'une différence de valeurs prix-surface dans la ville. Les limites se trouvent dans l'absence d'informations fines (état, qualité, étage, stationnement, différences spécifiques dans les quartiers) et à la modélisation spatiale encore simplifiée. Des prolongements naturels de ce travail pourrait inclure des structures spatiales plus riches (corrélations par proximité), des interactions ciblées (type de bien $\times$ surface), et une validation hors échantillon stricte (train/test temporel) pour consolider l'évaluation prédictive.

Références

- [1] Bates, D., Mächler, M., Bolker, B., Walker, S. (2015). Fitting Linear Mixed-Effects Models Using lme4. *Journal of Statistical Software*, 67(1), 1–48.
- [2] Kuznetsova, A., Brockhoff, P. B., & Christensen, R. H. B. (2017). lmerTest Package : Tests in Linear Mixed Effects Models. *Journal of Statistical Software*, 82(13), 1–26.
- [3] Wickham, H. (2016). *ggplot2 : Elegant Graphics for Data Analysis*. Springer.
- [4] OpenAI. (2025) ChatGPT (version GPT-4o mini) [Modèle de langage IA] : utilisé pour aider à la rédaction du code R.

5 Annexes




FIGURE 1 – Tous les logements DVF de Talence colorés par quartier. Les grappes de points suggèrent la forme des quartiers (fond OpenStreetMap).




FIGURE 2 – Prix moyens prédits par quartier à Talence (fond OpenStreetMap).




FIGURE 3 – Prix moyens prédits par quartier à Talence.